




# USO DE ANÁLISE DE DADOS PARA PREVER PRAGAS E DOENÇAS EM CULTURAS AGRÍCOLAS

**CURSO DE  
BIG-DATA**



**Aluno:** Júlio César Simieli

**Orientador:** Antônio Fernando Traina

**Escola:** Fatec



# Índice

**03** Introdução

**04** Escolha do Problema no Agronegócio

**05** Metodologia

**06/07** Desenvolvimento


**08** Justificativa da Importância do Projeto

**09** Objetivos do Projeto

**10** Público-Alvo do Projeto

**11** Conclusão






# Introdução

## Uso de Análise de Dados para Prever Pragas e Doenças em Culturas Agrícolas



O agronegócio enfrenta desafios constantes devido à incidência de pragas e doenças que comprometem a produtividade e aumentam os custos com defensivos agrícolas. O uso de tecnologias como IoT (Internet das Coisas) e Big Data pode ajudar na previsão e no controle desses problemas, permitindo que produtores adotem estratégias mais eficientes e sustentáveis.



# Escolha do Problema no Agronegócio

## 2.1 Descrição do Problema

Atualmente, muitos agricultores tomam decisões reativas no combate a pragas e doenças, o que pode resultar em uso excessivo de defensivos químicos e perdas na produção. A falta de informações precisas dificulta o planejamento e a implementação de medidas preventivas.



## 2.2 Evidências do Problema

Estudos indicam que pragas e doenças causam perdas significativas na produção agrícola, chegando a 40% da produção mundial em algumas culturas. Além disso, o uso descontrolado de pesticidas pode gerar impactos ambientais negativos e aumentar os custos de produção.

## 2.3 Impacto no Setor

A presença de pragas pode reduzir drasticamente a produtividade agrícola, aumentar a dependência de defensivos químicos e comprometer a qualidade dos produtos. Isso afeta diretamente a competitividade dos produtores no mercado.



# Metodologia

## 01 Metodologia 1

**Coleta e Tratamento de Dados:** São obtidos dados climáticos de fontes como o SBCDA e CIRAM, e informações sobre pragas da Embrapa e do sistema Agrofit. Após a coleta, os dados passam por limpeza e integração para formar um conjunto unificado.


## 02 Metodologia 2

**Análise Exploratória:** Utiliza-se visualização gráfica e estatísticas descritivas para identificar padrões e correlações nos dados.

## 03 Metodologia 3


**Modelagem Preditiva:** Aplicam-se algoritmos como Regressão Logística, Random Forest ou Redes Neurais para criar modelos que preveem a ocorrência de pragas. O desempenho dos modelos é avaliado com técnicas de divisão entre dados de treino e teste, além de validação cruzada.

# Desenvolvimento



## Coleta e registro de dados com Arduino:

Sensores conectados ao Arduino medem variáveis ambientais importantes, como temperatura, umidade e precipitação diretamente na plantação. Esses dados são armazenados e exportados para arquivos CSV.



## Carregamento e pré-processamento dos dados no Python:

Os arquivos CSV gerados pelo Arduino são importados para o Python, onde são tratados e integrados com dados adicionais, se houver. No Python, os dados passam por limpeza, removendo valores ausentes ou inconsistentes para garantir qualidade.



# Desenvolvimento


## Organização e análise inicial no Excel:

Os dados limpos podem ser exportados para o Excel para visualização simples, criação de tabelas e gráficos que ajudem a identificar padrões preliminares entre as variáveis ambientais e a ocorrência de pragas.

## Análise exploratória e modelagem preditiva no Python:

Com os dados organizados, são criadas visualizações mais avançadas (como mapas de calor de correlação) no Python para entender melhor as relações entre variáveis. Em seguida, um modelo preditivo, como Random Forest, é treinado para prever a presença de pragas com base nos dados coletados. O modelo é avaliado utilizando métricas de desempenho para garantir sua eficácia.

# Justificativa da Importância do Projeto



## Importância da resolução do problema


Resolver o problema da previsão de pragas traz benefícios como redução dos custos com defensivos agrícolas, aumento da produtividade ao evitar perdas e maior sustentabilidade ao diminuir impactos ambientais.

## Papel da IoT na solução

Sensores IoT coletam dados climáticos e ambientais em tempo real, permitindo detectar condições favoráveis para pragas. Esses dados são processados por algoritmos de Big Data e Machine Learning para prever surtos e sugerir ações preventivas.

## Exemplos de aplicações

Empresas já usam IoT para monitorar solo, temperatura e umidade, controlando pragas com mais eficiência. Um exemplo são armadilhas inteligentes que detectam insetos e enviam alertas aos produtores.





# Objetivos do Projeto

## Objetivo Geral

Desenvolver um sistema baseado em IoT e Big Data para prever a incidência de pragas e doenças agrícolas, auxiliando os produtores na tomada de decisões preventivas.



## Objetivos Específicos

- Coletar e integrar dados climáticos e ambientais usando sensores IoT.
- Analisar dados históricos de pragas para identificar padrões.
- Desenvolver um modelo preditivo baseado em Machine Learning.
- Criar um dashboard interativo para visualização das previsões.

# Público-Alvo do Projeto

## Quem se beneficiará da solução?

- Agricultores que buscam reduzir perdas e aumentar a eficiência.
- Cooperativas agrícolas que gerenciam grandes áreas de produção.
- Pesquisadores e empresas do setor interessados em otimizar o uso de insumos.



## Segmento do Agronegócio

O projeto pode ser aplicado em diferentes culturas agrícolas, como soja, milho, café e algodão, que sofrem frequentemente com ataques de pragas.

## Impacto para o Usuário Final

- Maior previsibilidade na ocorrência de pragas.
- Redução do uso de pesticidas através da aplicação mais eficiente.
- Maior lucratividade ao evitar perdas de produção.



# Script Python de Análise e Previsão

```
# modelo_pragas_milho.py
"""Treino de modelo para previsão de risco de pragas na cultura do milho."""
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
import joblib
from pathlib import Path

DATA_PATH = Path(__file__).parent.parent / "data" / "dados_milho_exemplo.csv"

def main():
    df = pd.read_csv(DATA_PATH)

    X = df[["temperatura", "umidade_ar", "umidade_solo"]]
    y = df["risco_praga"]

    model = RandomForestClassifier(
        n_estimators=200,
        max_depth=None,
        random_state=42
    )
    model.fit(X, y)

    # Salva modelo
    joblib.dump(model, "modelo_pragas_milho.pkl")

    # Previsão de exemplo
    sample = pd.DataFrame([[29.5, 85.0, 50.0]],
                           columns=["temperatura", "umidade_ar", "umidade_solo"])
    pred = model.predict(sample)[0]
    risco_str = "ALTO" if pred == 1 else "BAIXO"
    print(f"Risco de praga para a amostra: {risco_str}")

if __name__ == "__main__":
    main()
```

## Código do ESP32 (Sensores DHT22 e umidade do solo capacitivo)

```
#include <DHT.h>
#define DHTPIN 4
#define DHTTYPE DHT22
DHT dht(DHTPIN, DHTTYPE);

const int soilPin = 34; // Pino analógico
float temp, humidity, soilMoisture;

void setup() {
    Serial.begin(115200);
    dht.begin();
}



void loop() {
    temp = dht.readTemperature();
    humidity = dht.readHumidity();
    int soilRaw = analogRead(soilPin);
    soilMoisture = map(soilRaw, 0, 4095, 100, 0); // % de umidade

    Serial.print("Temp: "); Serial.println(temp);
    Serial.print("Umidade Ar: "); Serial.println(humidity);
    Serial.print("Umidade Solo: "); Serial.println(soilMoisture);

    delay(300000); // a cada 5 min
}
```



# Resultado



dados_milho_exemplo			
temperatura	umidade_ar	umidade_solo	risco_praga
21.8	80.2	38.8	0
31.7	74.9	38.8	0
28.4	81.6	57.6	1
22.1	95.0	32.3	0
29.7	93.6	21.7	0
26.0	67.3	46.9	0
25.5	81.9	37.2	0
24.3	93.8	49.8	1
29.8	84.3	25.4	0
28.6	92.5	47.2	1
32.0	69.4	23.1	0
24.3	82.0	57.4	1
27.7	83.1	25.7	0
29.5	76.1	48.8	0
22.3	73.1	23.2	0
29.0	70.6	43.2	0
24.0	94.7	53.8	1
21.2	81.4	28.4	0
24.2	78.4	37.1	0
25.3	92.3	32.6	0




# Dica para Previsão com Dados Ambientais


A ocorrência e severidade de pragas como a **lagarta-do-cartucho** ou a **cigarrinha** estão relacionadas a fatores como:

- Temperatura média elevada (25 °C a 30 °C)
- Alta umidade do ar (acima de 70 %)
- Baixa precipitação acumulada
- Plantio fora da época ideal (escapes de manejo regional)

**cigarrinha**



**lagarta-do-cartucho**





# Conclusão

A aplicação de tecnologias como IoT, Big Data e Machine Learning na previsão de pragas agrícolas está revolucionando o setor. Sensores conectados permitem a coleta em tempo real de dados ambientais, que são analisados por algoritmos capazes de prever surtos com antecedência. Isso permite aos produtores tomar decisões mais precisas e sustentáveis, reduzindo custos com defensivos, aumentando a produtividade e minimizando impactos ambientais. Assim, essas ferramentas se consolidam como aliadas essenciais para uma agricultura mais eficiente, moderna e inteligente.



# Referências

## PESQUISAS BIBLIOGRÁFICAS

<https://ciram.epagri.sc.gov.br/>

<https://www.alice.cnptia.embrapa.br/alice/handle/doc/915787>

<https://www.gov.br/agricultura/pt-br/assuntos/insumos-agropecuarios/insumos-agricolas/agrotoxicos/agrofit>

## TECNOLOGIAS E FERRAMENTAS

<https://www.arduino.cc/>

<https://www.python.org/>

<https://www.microsoft.com/pt-br/microsoft-365/excel>